五层心理评估系统

开发进程与 Schema 字段说明

用于项目进度汇报、代码逻辑复核和层间数据契约查阅

状态	维护者	更新时间
原型已形成五层闭环	项目开发者	2026 年 9 月 10 日

项目项	说明
文档范围	当前仓库中 L1 至 L5 的已完成代码逻辑、系统流程、验证情况和主要 Schema
主要读者	导师、项目组成员和后续维护者
使用方式	先阅读进程与流程，再按层查阅 Schema 字段释义
完整 Schema 参考	D:\develop\vscode\心理诊疗系统\docs\layer-schema-reference.md

一 当前结论

当前代码已经形成安全评估、MI 信息采集、患者确认、鉴别诊断、疗法匹配、治疗对话和输出审核组成的五层闭环原型。系统能够完成一次评估期到治疗期的转换，并在治疗期为每条患者消息重新执行安全检查和输出审核。

这一结果说明主要业务链路已经接通，但它仍是软件原型，不能等同于完整临床诊疗产品。量表优先级、危机资源转介、真人审核、长期疗程管理、持久化病历、统一 HTTP 接口和真实世界临床验证仍需继续建设。

二 整体运行逻辑

系统不会让每条消息机械地依次经过五层。评估期主要运行 L1 和 L2，画像经患者确认后才进入 L3；治疗期则由 L1、L3 动态指令、L4 和 L5 组成逐轮闭环。

序号	阶段	实际行为
1	启动	main.py 创建总会话并加载 API 配置
2	安全入口	患者消息进入 L1；危机或守卫失败时终止自动流程
3	信息采集	L2 使用 MI 访谈、辅助量表和证据节点构建患者画像
4	患者确认	确认后进入 L2→L3 守卫；修改或暂停留在 L2
5	诊断推理	L3 运行 CLINICR 候选生成、逐步排除和独立终验
6	疗法与指令	L3 用规则匹配基础疗法、插件和患者特征微调，并生成治疗指令
7	治疗生成	L4 只读取上游指令生成当前轮回复，不重新进行临床推理
8	独立审核	L5 检查伤害、边界和质量；失败时要求 L4 重写
9	持续治疗	通过审核的回复返回患者；下一条消息再次从 L1 开始

三 启动入口与顶层编排

本地运行入口是 main.py。它读取或询问 API 平台、接口地址、模型和密钥，创建 L1 至 L5 所需组件，启动终端对话，并显示患者回复、内部路由和开发者画像路径。

真正决定下一步调用哪一层的是 orchestration/orchestrator.py。编排器保存全局会话状态，并根据守卫结果、患者确认、诊断路由和审核结果切换阶段。

路由状态	含义
L2_INTERVIEW	正在进行普通 MI 评估访谈
L2_SCALE	正在执行患者已同意的量表
L2_DIAGNOSTIC_CONTEXT	正在补充进入 L3 所需的鉴别信息
AWAITING_PATIENT_CONFIRMATION	患者画像已生成，等待确认、修改或暂停
L3_PROCESSING	患者画像正在进入诊断推理
RETURN_TO_L2	L3 发现证据不足，携带缺失项返回 L2
L4	已进入治疗对话阶段
MANUAL_REVIEW	自动审核或重写无法完成，需要人工复核
PAUSED_BY_PATIENT	患者主动暂停
STOPPED	危机、安全失败或不可恢复错误导致流程终止

四 L1 安全评估层

1. 关键词风险检测由规则执行。
2. 越狱和提示注入检测由规则执行。
3. 语义风险分类调用真实 LLM。
4. 风险融合规则合并关键词、LLM、量表上下文和越狱结果。
5. 策略执行器生成并执行安全命令。
6. L1 出口守卫验证安全决定是否真正执行。

每一条新的患者消息都必须重新经过 L1，包括已进入治疗阶段后的消息。若 L1 模型不可用、输出不合法或守卫失败，系统采用 fail closed，不允许消息进入后续层。

五 L2 MI 评估层

L2 的核心任务是收集足够好的信息，而不是下诊断。对话按参与、聚焦、唤出和计划四个 MI 阶段平滑推进，阶段名称不会直接显示给患者。

L2 中的 LLM 工作

- 识别自然语言输入类型。
- 提取症状、情绪、认知模式、患者目标和关键叙述。
- 把复杂自然语言转换为受约束的结构化候选字段。
- 生成符合 MI 风格的回复。

L2 中的规则工作

- 验证 L1 命令和会话消息绑定。
- 决定 MI 阶段转换。
- 验证患者原话并生成证据节点。
- 控制量表触发许可、题号、分值范围、计分和阈值。
- 判断画像信息是否充分。
- 处理患者画像确认并执行 L2→L3 接口守卫。

模型提取的字段只是候选事实，必须携带 evidence_quote，并由规则确认该原话确实存在于患者消息中，之后才能写入画像。

六 患者画像与确认

L2 患者画像保存主要症状、情绪、认知模式、关键叙述、功能影响、病程、患者目标、改变动机、量表结果和鉴别诊断所需信息。每项临床事实尽量绑定患者原话和证据节点。

1. 开发者可以查看完整患者画像 HTML。
2. 患者看到脱敏确认卡，而不是内部诊断分数。
3. 患者可以确认、要求修改或暂停。
4. 只有患者确认且 L2 出口守卫通过，画像才能进入 L3。

七 L3 诊断与疗法决策层

CLINICR 三步推理

1. 候选诊断生成：LLM 同时考虑规定的十种障碍并生成三至五个候选，记录症状匹配数、核心证据、证据引用和候选置信度。

2. 逐步排除验证：LLM 对每个候选逐条核对 DSM-5 或 ICD-11 条目，并分为满足标准、待观察或排除。每项判断只能引用 L2 中真实存在的证据。
3. 独立终验：Verifier 只审核排名第一候选的证据充分性、逻辑连贯性、鉴别覆盖和推理跳跃，不接收候选置信度，避免复制前面的结论。

候选置信度和 Verifier 评分是两个独立指标。候选置信度低于 0.5 时不能进入疗法匹配；Verifier 可以路由为 pass、conditional、return_to_l2、manual_review 或 reject。

疗法选择三步链

1. 主诊断映射基础疗法，例如 MDD 映射 CBT 加行为激活，失眠障碍映射 CBT-I。
2. 量表阈值和症状特征触发最多两个插件。L3 只输出插件名称、依据和使用要求，不在本层调用插件 API。
3. 规则根据严重程度、改变动机、精神病性症状、活跃物质依赖、严重解离和安全风险微调策略。

四段治疗指令

治疗指令中的 L1 至 L4 是四个提示词区段，不是系统的五个层级。指令 L1 定义治疗师角色，指令 L2 保存诊断锚点，指令 L3 描述本轮目标和技术并在每轮重写，指令 L4 保存绝对禁令和安全触发条件。

八 L4 治疗对话层

1. 患者消息先重新经过 L1。
2. L3 动态指令模型根据治疗历史生成当前轮指令。
3. 规则守卫检查动态指令是否符合上游诊断和疗法边界。
4. L4 拼接角色、诊断锚点、本轮指令、防越界要求和历史。
5. L4 调用真实 LLM 生成患者回复。
6. 本地规则先检查回复，再将完整上下文交给 L5。

L4 内部阶段为共情、反馈、技术执行和巩固。L4 只能执行上游批准的诊断和治疗计划，不能自行诊断新疾病或改变主诊断。

九 L5 独立输出审核层

L5 对 L4 的候选回复进行 harm、boundary 和 quality 三项检查。审核上下文包含患者本轮原话、历史治疗对话、L1 风险信息、L3 诊断锚点、本轮动态指令和 L4 原始回复。

审核结果	后续动作
三项全部 pass	将回复发送给患者
任意一项 fail	返回失败原因和修复指令，由 L4 重写
多次重写仍失败	暂停自动治疗并进入 MANUAL_REVIEW
审核输出无法解析	按不通过处理，不默认放行

十 规则与 LLM 的职责边界

位置	LLM 负责	规则负责
L1	语义风险分类	关键词、越狱检测、风险融合、策略执行、出口守卫
L2	输入类型识别、语义提取、复杂字段转换、MI 回复	阶段转换、量表、证据、充分度、患者确认、接口守卫
L3	候选诊断、逐条排除、Verifier、动态治疗指令	前置契约、置信度门槛、疗法选择、指令守卫、输出验证
L4	依据治疗指令生成回复	阶段状态机、本地越界检查、重写次数和人工复核路由
L5	结合完整上下文评估伤害、边界和质量	输入完整性、三项全通过条件、失败时阻止放行

十一 已完成验证与当前边界

最近一次真实全局测试已经完成 L1 安全评估、L2 信息采集和 PHQ-9、患者确认、L3 CLINICR 与 Verifier、L3 动态治疗指令、L4 回复生成以及 L5 审核。最终路由保持 L4，没有进入人工复核或安全阻断。

该次汇报记录中的自动化测试结果为 333 passed。此数字说明受控测试覆盖的代码路径通过，不代表真实 API 长期稳定，也不证明临床有效性。

尚未完成的部分	影响
量表就绪门	当前 L2 可能在访谈信息不足时过早邀请量表
完整危机资源与真人转介	高风险处置还不能形成现实世界闭环
专业人员审核后台	MANUAL_REVIEW 暂无真人处理界面
病历持久化与跨会话恢复	会话退出后不能从画像 HTML 恢复
完整疗程管理	作业、疗效监测、阶段复评、结案和随访仍需开发
统一五层 HTTP 接口与患者前端	当前完整入口主要是本地终端 main.py

尚未完成的部分	影响
临床有效性验证	软件测试通过不能替代临床研究和专业审核
全输出统一审核	L5 当前主要审核 L4 治疗回复，尚未覆盖所有系统输出

十二 Schema 阅读说明

Schema 是层与层之间约定的数据结构。它规定字段名称、数据类型、必填条件和允许值，使上游输出能够被下游稳定读取。Schema 通过只说明数据格式和基本约束，不等于临床结论正确。

类型写法	中文含义	示例
str	字符串，也就是一段文本	session_id 或 summary
int	整数	risk_level 或 severity_level
float	可带小数的数值	confidence 或 verifier_score
bool	布尔值，只能是 true 或 false	crisis_flag
list[T]	由多个同类型项目组成的列表	list[str]
dict[K,V]	键值对象，键和值分别受类型约束	dict[str, Any]
Literal[...]	只能从列出的固定值中选择	pass、warn、block
NoneType	字段可以为空	str | NoneType
Any	允许多种 JSON 类型，仍应由业务规则限制	structured_labels
必填	创建对象时必须提供	缺少后 Schema 校验失败
默认值	调用方没有提供时由模型自动填入	默认空列表或 0
工厂生成	每次创建对象时生成独立默认容器或时间	空列表、空字典、时间戳

下列内容收录每层主接口 Schema 和决定行为的关键嵌套结构。完整内部模型清单以 docs/layer-schema-reference.md 为准。只要 L1 至 L5 的 Pydantic 模型或 TypedDict 发生变化，就必须重新生成并同步该参考文档。

十三 L1 Schema

SafetyPassport

L1 发送给 L2 和后续层的安全通行证。它同时保存风险判断、执行结果和守卫凭证。

源码位置 `shared/schemas/safety_schema.py`

字段	类型	必填	字段含义
schema_version	Literal['1.0']	是	接口版本。用于发现上下游是否使用了不兼容的数据格式。
layer_id	Literal['L1']	是	数据来源层，固定为 L1。
session_id	str	是	全局会话标识，用来防止不同患者会话的数据混用。
message_id	str	是	当前患者消息标识。L2 入口守卫据此确认安全结果属于本条消息。
timestamp	str	是	安全评估产生时间。
safety_flag	pass | warn | block	是	总体安全状态。pass 可继续，warn 带限制继续，block 阻止常规流程。
risk_level	int	是	风险等级，当前使用 0 至 3。数值越高，处置越严格。
risk_types	list[str]	是	识别出的风险类别，例如 self_harm。
crisis_flag	bool	是	是否进入危机处理条件。
sensitive_topics	list[str]	是	需要限制追问或谨慎处理的主题。
summary	str	是	面向开发者的安全判断摘要。
structured_labels	dict[str, Any]	是	风险分项、量表跳过列表和安全追问要求等机器可读标签。
evidence_refs	list[EvidenceRef]	是	支持风险判断的证据记录。
confidence	float	是	L1 对语义分类结果的置信度，通常在 0 至 1。
flags	list[str]	是	需要下游持续执行的控制标记。
instruction_to_next	str	是	L1 交给下一层的自然语言处置说明。
execution	dict[str, Any]	是	策略执行回执，记录路由、终止状态和实际执行的命令。
guard	dict[str, Any]	是	L1 出口守卫结果，说明是否允许调用 L2 以及违反了哪些规则。

EvidenceRef

L1 风险结论使用的最小证据结构。

源码位置 `shared/schemas/safety_schema.py`

字段	类型	必填	字段含义
source	str	是	证据来源，例如规则引擎或语义模型。
finding	str	是	该来源发现了什么。
basis	str	是	为什么该发现支持当前判断。

SafetyModelUnavailable

L1 语义安全模型不可用时返回的终止错误结构。

源码位置 `shared/schemas/safety_schema.py`

字段	类型	必填	字段含义
status	Literal['error']	是	固定表示错误结果。
error_code	L1_LLM_UNAVAILABLE	是	专门区分 L1 模型不可用。
message	str	是	可显示或记录的错误说明。
terminal	Literal[True]	是	明确本次流程已经终止。
can_call_l2	Literal[False]	是	明确禁止继续调用 L2。
details	dict[str, Any]	是	保存错误阶段和异常类型等调试信息。
evidence_refs	list[EvidenceRef]	是	记录规则侧已经发现的安全证据，但不用于绕过模型失败。

十四 L2 Schema

ClinicalIntake

L2 交给 L3 的患者画像主接口。它必须同时表达画像内容、证据、充分度和患者确认状态。

源码位置 `layers/layer2/schemas/models.py`

字段	类型	必填	字段含义
layer_id	Literal['L2']	否	数据来源层，默认 L2。
timestamp	str	否	画像生成或更新时间。
session_id	str	是	画像所属会话。
current_stage	MIStage	是	画像生成时所在的 MI 阶段。
key_symptoms_extracted	list[SymptomEvidence]	否	已确认的主要症状及证据。
emotions	list[ProfileFact]	否	从患者原话中提取的情绪状态。
cognitive_patterns	list[ProfileFact]	否	自动化思维、核心信念或其他认知模式。
patient_goals	list[str]	否	简化后的患者目标文本。
patient_goal_facts	list[ProfileFact]	否	带原话证据的患者目标。
key_narratives	list[ProfileFact]	否	对评估重要的关键叙述。
functional_impairments	list[ProfileFact]	否	工作、学习、人际或生活功能受到的影响。
focus_topics	list[str]	否	患者确认的当前讨论重点。
focus_topic_facts	list[ProfileFact]	否	带证据的讨论重点。
change_talk	list[ProfileFact]	否	表达改变意愿、理由或能力的语句。
sustain_talk	list[ProfileFact]	否	表达维持现状、犹豫或阻力的语句。
motivation	MotivationScores	是	重要性、信心和准备度评分及来源。
scale_results	dict[str, ScaleResult]	否	各量表的状态、逐题分数、总分和阈值。
diagnostic_context	DiagnosticContext	是	L3 鉴别诊断和疗法微调需要的背景字段。
evidence_nodes	list[EvidenceNode]	否	患者原话和量表答案形成的证据图节点。
information_sufficiency	insufficient | sufficient	是	L2 是否认为画像达到进入 L3 的最低信息要求。

字段	类型	必填	字段含义
missing_dimensions	list[str]	否	仍缺少的临床信息维度。
patient_confirmation	ConfirmationStatus	是	患者是否已经确认画像，或要求修改、暂停。
safety_controls	list[str]	否	从 L1 继承并持续生效的安全控制。
flags	list[str]	否	L2 产生的内部状态和异常标记。
l2_validation	dict[str, Any]	否	L2 出口守卫校验结果。

EvidenceNode

统一证据节点，使 L3 能从画像字段追溯到具体患者消息或量表题目。

源码位置 layers/layer2/schemas/models.py

字段	类型	必填	字段含义
evidence_id	str	是	证据节点唯一标识。
source_type	patient_message | scale_item	是	证据来自患者自然语言还是量表题目。
message_id	str	是	证据所属消息。
turn_index	int	是	证据出现的对话轮次，从 1 开始。
quote	str	是	患者原话或量表回答文本。
target_path	str	是	该证据支持的画像字段路径。
created_by	规则枚举	是	说明节点由经规则核验的 LLM 候选或量表规则生成。
parent_ids	list[str]	否	上游证据节点，用于表达证据之间的关系。

DiagnosticContext

进入 L3 前需要补齐的鉴别诊断背景和疗法插件条件。

源码位置 layers/layer2/schemas/models.py

字段	类型	必填	字段含义
symptom_duration_days	int | None	否	关键症状持续天数。
functional_impairment	bool | None	否	症状是否造成明显功能影响。

字段	类型	必填	字段含义
mania_or_hypomania_history	bool | None	否	是否存在躁狂或轻躁狂史。
substance_or_medical_cause	bool | None	否	症状是否可能由物质、药物或躯体疾病解释。
differential_diagnoses_assessed	list[str] | None	否	已经核对过的鉴别诊断。
evidence_conflicts	list[dict] | None	否	量表、叙述或其他证据之间尚未解决的矛盾。
relapse_count	int | None	否	既往复发次数，用于插件判断。
rhythm_disturbance	bool | None	否	是否存在明显节律紊乱。
exposure_avoidant	bool | None	否	是否对暴露治疗存在显著抵触或回避。
ritual_behaviors	bool | None	否	是否存在强迫仪式行为。
insomnia_chief_complaint	bool | None	否	失眠是否为主要诉求。
chronic_months	int | None	否	相关问题持续月数。
interpersonal_conflicts	int | None	否	重要人际冲突事件数量。
interpersonal_impairment	bool | None	否	人际功能是否受损。
single_focus	bool | None	否	问题是否单一且适合聚焦处理。
psychotic_symptoms	bool | None	否	是否存在精神病性症状信号。
substance_active	bool | None	否	是否处于活跃物质依赖期。
severe_dissociation	bool | None	否	是否存在严重解离。
sources	dict[str, list[str]]	否	每个诊断背景字段对应的证据节点列表。

ScaleResult

单个量表从触发到完成或拒绝的完整状态。

源码位置 `layers/layer2/schemas/models.py`

字段	类型	必填	字段含义
scale_name	ScaleName	是	量表名称，如 PHQ-9、GAD-7 或 ISI。
status	ScaleStatus	否	未开始、待同意、进行中、已完成、拒绝或跳过。

字段	类型	必填	字段含义
items	dict[int, int]	否	题号与患者分值。
score	int | None	否	规则计算的量表总分。
threshold	str | None	否	总分对应的分级或阈值说明。
evidence_ids	list[str]	否	每个答案产生的证据节点。
skip_reason	str	否	量表被跳过或禁止时的原因。

DialogueResult

L2 自然语言适配器每处理一条消息返回的结果。

源码位置 layers/layer2/schemas/models.py

字段	类型	必填	字段含义
accepted	bool	是	本条消息是否被成功理解并写入状态。
reply	str	是	显示给患者的 L2 回复。
awaiting	str | None	否	下一条消息期望的输入类型。
l2_turn	L2Turn | None	否	本轮阶段、量表触发和证据摘要。
error_code	str | None	否	失败时的机器可读错误码。
confirmation_decision	continue | revise | pause	否	患者对画像确认卡的选择。

十五 L3 Schema

DiagnosticCandidate

CLINICR 第一步生成的单个候选诊断。

源码位置 `layers/layer3/diagnosis/schemas.py`

字段	类型	必填	字段含义
`disorder`	`DisorderCode`	是	十种受支持障碍中的标准代码。
`label`	`str`	是	便于阅读的诊断名称。
`symptom_match`	`SymptomMatch`	是	患者症状与诊断标准条目的匹配数和总数。
`core_evidence_summary`	`str`	是	支持该候选的关键画像信息摘要。
`evidence_refs`	`list[str]`	是	该候选引用的 L2 证据节点。
`confidence`	`float`	是	候选生成模型给出的初步主观支持度，范围 0 至 1。

CriterionAssessment

CLINICR 第二步对一条 DSM-5 或 ICD-11 标准的核对结果。

源码位置 `layers/layer3/diagnosis/schemas.py`

字段	类型	必填	字段含义
`code`	`str`	是	标准条目编号，例如 A1。
`name`	`str`	是	条目名称或简述。
`status`	`met | not_met | pending`	是	已满足、不满足或信息待确认。
`rationale`	`str`	是	为何作出该状态判断。
`evidence_refs`	`list[str]`	否	支持该条目判断的患者画像证据。

RewardModelAssessment

独立 Verifier 对排名第一候选推理质量的终验结果。

源码位置 `layers/layer3/diagnosis/schemas.py`

字段	类型	必填	字段含义
score	float	是	四个质量维度综合得到的终验分数。
dimensions	list[VerifierDimension]	是	证据充分、逻辑连贯、鉴别覆盖和无推理跳跃四项评分。
fail_reasons	list[str]	否	未通过或条件通过的具体原因。
missing_dimensions	list[MissingDimension]	否	需要 L2 继续追问的字段、目的和建议问题。

DiagnosticReport

L3 交给 L4 的诊断、疗法和指令主接口。只有通过 L3 输出校验的报告才能进入 L4。

源码位置 layers/layer4/schemas/l3_report.py

字段	类型	必填	字段含义
layer_id	str	否	来源层，默认 L3。
timestamp	str	否	诊断报告生成时间。
diagnosis	Diagnosis	否	主诊断、共病、待观察和已排除诊断。
provisional_diagnosis	PrimaryDiagnosis | None	否	条件通过时保存的暂定诊断。
verifier_score	float	否	独立终验综合分数。
verifier_decision	str	否	终验给出的文字或枚举决定。
candidate_confidence	float	否	排名第一候选在第一步得到的初步置信度。
verifier_routing	str	否	pass、conditional、return_to_l2、manual_review 或 reject。
verifier_checks	list[VerifierCheck]	否	每个终验维度的状态、分数、权重、理由和证据。
verifier_fail_reasons	list[str]	否	终验失败原因。
recommended_therapy	RecommendedTherapy	否	基础疗法、插件、微调策略和禁忌。
severity_level	int	否	严重程度的结构化等级。
clinical_notes_for_L4	str	否	L4 生成治疗回复时需要遵守的临床说明。
summary	str	否	诊断和疗法结果摘要。
structured_labels	StructuredLabels	否	疗法路由、措辞限制和风险监测标签。
evidence_refs	list[EvidenceRefIn]	否	DSM 条目、疗法和规则所引用的结构化证据。

字段	类型	必填	字段含义
confidence	float	否	报告层面的总体置信度。
flags	list[str]	否	需要下游注意的诊断或安全标记。
instruction_to_next	str	否	交给 L4 或回到 L2 的自然语言指令。
missing_dimensions	list[MissingDimension]	否	信息不足时需要补采的字段。
l3_validation	L3ValidationReceipt | None	否	L3 输出规则校验凭证和报告哈希。
instructions	dict[str, Any]	否	L3 生成的四段治疗指令。

TreatmentInstructions

L3 与 L4 之间唯一的治疗执行接口。字段名 L1 至 L4 代表指令区段。

源码位置 shared/schemas/treatment_instructions.py

字段	类型	必填	字段含义
L1	RoleInstruction	是	治疗师身份、语言风格和会话边界，全会话复用。
L2	DiagnosticAnchor	是	主诊断、共病、排除项、核心信念、插件、疗法和置信度等静态锚点。
L3	TurnInstruction | None	否	本轮目标、技术、禁令、上下文和证据，每轮重新生成。
L4	BoundaryInstruction	是	绝对禁止事项和安全触发条件，每轮复用。

TurnInstruction

治疗期每一轮由 L3 生成并交给 L4 的动态执行指令。

源码位置 shared/schemas/treatment_instructions.py

字段	类型	必填	字段含义
goal	str	是	当前这一轮的具体治疗目标。
technique	str	是	建议使用的治疗技术名称。
forbidden	list[str]	否	本轮禁止行为，例如过早给建议。
link_previous	str	否	如何衔接上一轮内容。
plugin_guidance	str | None	否	已激活插件在本轮的嵌入方式。

字段	类型	必填	字段含义
force_substage	L4Substage | None	否	要求 L4 使用的内部治疗子阶段。
session_id	str	否	指令所属会话。
turn_number	int	否	治疗轮次编号。
source_message	str	否	用于规划本轮指令的患者原话。
technique_code	str	否	规则可验证的标准技术代码。
plugin_steps	dict[str, str]	否	每个插件对应的可执行步骤。
evidence	list[SourceQuote]	否	本轮指令所依据的患者原话。
observations	list[ProgressObservation]	否	患者反应、作业完成或未解决问题。
previous_goal_met	bool	否	上一轮目标是否达成。
patient_ready	bool	否	患者是否准备进入更具行动性的技术。
rationale	str	否	为什么选择当前目标和技术。

十六 L4 Schema

SessionRequest

创建 L4 治疗会话的输入。

源码位置 `layers/layer4/service.py`

字段	类型	必填	字段含义
session_id	str | None	否	可复用上游会话 ID；为空时生成新 ID。
report	DiagnosticReport	是	已经通过 L3→L4 守卫的诊断与疗法报告。
safety	SafetyPassport	否	L4 需要持续遵守的 L1 风险信息。

TurnRequest

L4 每轮生成治疗回复的输入。

源码位置 `layers/layer4/service.py`

字段	类型	必填	字段含义
session_id	str	是	目标治疗会话。
user_message	str	是	患者当前轮自然语言。
turn	TurnInstruction	是	L3 为本轮生成且已通过守卫的动态指令。

TurnOutcome

L4 完成生成和 L5 审核后的结果。

源码位置 `layers/layer4/service.py`

字段	类型	必填	字段含义
session_id	str	是	结果所属治疗会话。
reply	str	是	最终允许发送给患者的回复，或安全兜底回复。
l4_substage	L4-L1 至 L4-L4	是	当前内部治疗阶段：共情、反馈、技术执行或巩固。
l5_context	L5Context	是	本轮送审时使用的完整上下文快照。

字段	类型	必填	字段含义
summary	StructuredSummary	是	供后续轮次使用的结构化摘要。
review_history	list[ReviewResult]	是	首次生成和各次重写对应的 L5 审核记录。
fallback_used	bool	否	是否因多次审核失败使用兜底并转人工复核。

StructuredSummary

L4 为后续轮次和追溯生成的结构化会话摘要。

源码位置 layers/layer4/schemas/summary.py

字段	类型	必填	字段含义
layer_id	Literal['L4']	否	来源层，固定 L4。
timestamp	str	是	摘要生成时间。
summary	str	是	本轮治疗内容摘要。
structured_labels	dict[str, Any]	是	本轮阶段、技术和状态等机器可读标签。
evidence_refs	list[EvidenceRef]	否	摘要内容引用的证据。
confidence	float	否	摘要可靠度。
flags	list[str]	否	后续轮次需要关注的内部标记。

十七 L5 Schema

L5Context

L4 交给 L5 的完整审核上下文。L5 必须看到原始回复、患者原话、历史、指令和风险信息。

源码位置 `layers/layer4/schemas/l5_context.py`

字段	类型	必填	字段含义
`l4_raw_output`	`str`	是	L4 尚未发给患者的原始候选回复。
`l4_substage`	`L4Substage`	是	当前回复所属的 L4 内部治疗阶段。
`therapy_type`	`str`	是	L3 批准的基础疗法。
`user_message`	`str`	是	患者当前轮原话，不能为空。
`history`	`list[ConversationTurn]`	是	此前患者与系统的治疗对话。
`instructions`	`TreatmentInstructions`	是	完整四段治疗指令，包含本轮动态指令。
`diagnosis_context`	`DiagnosisContext`	否	主诊断、共病和自杀意念摘要。
`risk_context`	`RiskContext`	否	L1 风险等级、敏感主题和安全标记。

ReviewResult

L5 对候选回复进行三项独立检查后的输出。

源码位置 `layers/layer4/schemas/review.py`

字段	类型	必填	字段含义
`harm`	`pass | fail`	是	回复是否可能造成伤害或弱化必要的安全处置。
`boundary`	`pass | fail`	是	回复是否越过心理支持和治疗执行边界。
`quality`	`pass | fail`	是	回复是否符合当前疗法、阶段和本轮动态指令。
`fail_reason`	`str`	否	任一检查失败时说明具体问题。
`fix_instruction`	`str`	否	交给 L4 重写模型的可执行修复要求。

DiagnosisContext

L5 审核所需的最小诊断背景。

源码位置 `layers/layer4/schemas/l5_context.py`

字段	类型	必填	字段含义
`primary`	`str`	否	主诊断或初步诊断。
`secondary`	`list[str]`	否	共病或次要诊断。
`suicidal_ideation`	`str | None`	否	与当前安全审核有关的自杀意念信息。

RiskContext

L5 审核所需的最小安全背景。

源码位置 `layers/layer4/schemas/l5_context.py`

字段	类型	必填	字段含义
`risk_level`	`int`	否	L1 当前风险等级。
`sensitive_topics`	`list[str]`	否	需要避免误触或谨慎回应的主题。
`flags`	`list[str]`	否	仍需执行的安全控制标记。

十八 顶层编排 Schema

OrchestrationOutcome

顶层编排器每处理一条消息后交给终端或未来前端的统一结果。

源码位置 `orchestration/schemas.py`

字段	类型	必填	字段含义
`session_id`	`str`	是	当前全局会话。
`route`	`PipelineRoute`	是	系统当前所在层级或等待状态。
`reply`	`str`	是	本轮可显示给患者的文字。
`waiting_for`	`str | None`	否	下一条消息期望的输入类型。
`terminal`	`bool`	否	本次会话是否已经终止。
`confirmation`	`PatientConfirmation | None`	否	信息充分时生成的患者确认卡。

PatientConfirmation

患者画像完成后显示给患者的脱敏确认卡。

源码位置 `orchestration/schemas.py`

字段	类型	必填	字段含义
`title`	`str`	是	确认卡标题。
`profile_summary`	`list[str]`	否	主要症状、病程、功能影响和目标摘要。
`scale_summary`	`list[str]`	否	已完成量表及分数摘要。
`initial_impression`	`str`	是	非确诊措辞的初步整理。
`disclaimer`	`str`	是	量表和系统输出不能替代专业诊断的说明。
`next_step`	`str`	是	确认后系统将执行的动作。
`actions`	`continue | revise | pause`	否	患者可以选择继续、修改或暂停。

十九 下一步工作

优先级	工作项	完成标准
P0	增加量表就绪门	在充分开放访谈和必要澄清前不主动邀请量表；高风险量表题除外
P0	建设危机转介闭环	按地区展示可用资源，支持真人接管并记录处置结果
P1	持久化会话和病历	安全保存状态、支持跨进程恢复并具有审计和删除机制
P1	统一五层 HTTP 接口	前端只调用编排器 API，不直接逐层调用
P1	专业审核后台	能够处理 MANUAL_REVIEW、记录决定并安全恢复会话
P2	完整疗程管理	支持疗程目标、家庭作业、疗效复评、结案和随访
P2	临床与真实 API 评估	分别验证可靠性、响应时间、证据一致性和临床安全性

二十 汇报摘要

当前项目已经完成基于顶层编排器的五层心理评估与治疗原型。评估期由 L1 完成安全筛查，L2 通过 MI 访谈和辅助量表构建可追溯的患者画像；患者确认后，L3 使用 CLINICR 三步法进行鉴别诊断，并通过规则完成疗法选择和治疗指令生成；治疗期每轮重新经过 L1 安全检查，由 L3 生成动态指令、L4 执行治疗对话、L5 进行输出审核，不通过时自动重写或转人工复核。当前下一步重点是降低量表依赖，并补齐长期疗程管理、真人转介、数据持久化和统一前端接口。