心理诊疗系统五项后续开发任务说明

前端 L2 问诊知识库 L3 临床知识库 Patient Agent 通用 RAG 检索引擎

用途 团队任务分配和开发验收

适用项目 五层心理诊疗大模型系统

版本日期 2026-09-12

文档目的

本文将五项后续开发工作拆分为可直接分配的工作包，明确每项工作的功能边界、实施步骤、接口、交付物、依赖关系和验收标准。现有 L1 至 L5 主流程继续保留，新增模块通过统一 Schema 和顶层编排器接入，不重新实现已经完成的安全分类、MI 阶段控制、CLINICR、治疗指令或 L5 单轮审核。

五项工作的共同目标是让系统获得可检索的问诊与临床知识、可重复的患者模拟能力，以及可以用于项目展示的统一交互界面。L2 知识库负责帮助系统决定如何提问，L3 知识库负责提供诊断标准依据，通用 RAG 只负责检索，Patient Agent 只负责模拟测试患者，前端只通过完整系统 API 与顶层编排器交互。

五项工作边界

工作包	解决的问题	不负责的内容	主要依赖
通用 RAG 检索引擎	统一完成知识索引 Top K 检索 过滤 重排和引用返回	不诊断 不生成患者事实 不决定 MI 阶段	知识库 Schema 和数据
L2 问诊知识库	提供 MI 话术 症状追问和量表自然引入范式	不生成诊断标签 不替代量表规则	通用 RAG 和现有 L2
L3 临床知识库	提供疾病标准 排除条件 鉴别诊断和来源版本	不保存患者事实 不直接生成治疗回复	通用 RAG 和现有 CLINICR
Patient Agent	模拟稳定一致的患者并自动完成多轮测试	不作为临床金标准 不进入生产患者流程	病例 Schema 和完整系统 API
前端	提供患者对话 开发者流程观察和项目演示	不直接调用单层 不在界面内做临床判断	顶层编排器和完整系统 API

总体依赖关系

数据整理和接口设计可以并行启动，模块接入必须按以下依赖顺序推进。

1. 先冻结 RetrievedKnowledge L2KnowledgeCard ClinicalCriterion PatientScenario 等共享 Schema。
2. L2 和 L3 知识负责人分别整理数据，RAG 负责人同步搭建通用检索能力。
3. 通用 RAG 完成后，L2 和 L3 负责人分别接入对应知识库。
4. 顶层编排器提供完整系统 API 后，Patient Agent 和前端再进行端到端联调。

5. 五项工作最终进入同一套单元测试 接口测试 受控模型测试和真实 LLM 测试。

一 通用 RAG 检索引擎

通用 RAG 是公共基础设施，负责把查询转换成可追溯的知识片段。它同时服务 L2 和 L3，但两层使用独立知识集合、过滤规则和访问权限。RAG 返回资料及来源，不进行诊断，也不能把知识片段写成患者事实。

功能流程

6. 接收查询文本 collection Top K 元数据过滤条件和调用层级。
7. 根据 collection 选择 L2 问诊库或 L3 临床库，禁止跨库混检。
8. 执行关键词与向量混合检索，并按元数据进行精确过滤。
9. 对候选结果去重和重排，低于相关性阈值的结果不返回。
10. 返回 knowledge id 内容 来源 版本 位置 分数和索引版本。
11. 记录检索日志，供开发者界面和问题追踪使用。

核心接口

接口字段	类型	含义	控制方式
collection	字符串枚举	指定 L2 问诊库或 L3 临床库	规则白名单
query	字符串	当前检索请求	调用层构造
top k	整数	最多返回的结果数量	配置限制
filters	对象	阶段 疾病代码 版本 来源类型等过滤条件	规则生成
results	数组	检索到的结构化知识条目	Schema 校验
index version	字符串	本次使用的索引版本	系统写入

任务清单

编号	任务	具体工作	交付物	验收标准
R1	统一检索 Schema	定义查询 过滤条件 检索结果 来源和索引版本字段	Pydantic 模型和字段文档	非法集合 未知字段和缺失来源会被拒绝

编号	任务	具体工作	交付物	验收标准
R2	知识导入	读取标准化知识卡 校验来源 生成索引记录	导入器和错误报告	坏数据不能进入索引 每条记录可追溯
R3	索引构建	建立关键词索引和向量索引 保存版本	可重建索引和清单	同一版本可重复构建且记录数一致
R4	混合检索	实现元数据过滤 关键词召回 向量召回 去重和 Top K	统一 retriever 接口	L2 与 L3 集合隔离 Top K 和阈值生效
R5	重排策略	优先保留来源质量 高匹配度和不同用途的结果	reranker 和配置	不返回大量重复范式或错误疾病资料
R6	安全控制	把检索内容标记为数据 防止知识文本覆盖系统指令	输入清洗和提示边界	恶意知识条目不能改变调用层职责
R7	日志与观测	记录查询 过滤条件 命中条目 分数 延迟和版本	结构化检索日志	能定位空结果 错库和低相关问题
R8	检索评测	建立固定查询集 计算命中率 相关性和来源完整率	评测脚本与报告	关键查询能找到预期条目且无跨库结果

负责人交付边界

- 建议负责人 RAG 或算法工程成员。
- 允许修改 新建 retrieval 目录 shared 中的检索 Schema 和配置。
- 不得修改 L2 阶段规则 L3 诊断门槛和 L4 治疗策略。
- 完成定义 L2 和 L3 能通过同一接口检索各自知识，并返回可验证来源。

二 L2 问诊知识库

L2 知识库用于改善 MI 访谈，不用于诊断。它向 L2 模型提供当前阶段适用的 OARS 话术、症状探索范式、量表说明和自然衔接示例。知识条目只能作为语言和策略参考，不能成为患者画像证据。

知识范围

知识类别	必须覆盖的内容	主要检索条件
MI 阶段	参与 聚焦 唤出 计划四个阶段的目标和语言范式	当前阶段和阶段目标
OARS 技术	开放式提问 肯定 简单反映 复杂反映 总结	允许技术和患者表达
症状探索	抑郁 焦虑 创伤 强迫 失眠 躁狂史 精神病性症状 物质和躯体影响	症状领域和缺失画像字段
量表引入	PHQ 9 GAD 7 PCL 5 Y BOCS ISI MDQ 的解释 同意 拒绝和中断	量表领域和许可状态
目标与动机	患者目标 改变重要性 信心 矛盾心理和阻力	MI 阶段和动机水平
错误范式	机械复述 连续多问 过早量表化 提前诊断和给建议	输出校验失败类型

知识卡字段

每条知识卡至少记录 knowledge id 来源 许可 语言 MI 阶段 OARS 技术 症状领域 对话目的 患者表达模式 待补字段 推荐示例 反例 使用理由 量表领域 禁忌 标签 版本和人工审核状态。来源和许可字段必须在导入索引前完成。

接入现有 L2 的流程

12. L2 语义模型从患者消息中提取症状 情绪 意图和可能量表领域。
13. 规则读取当前 MI 阶段 待补字段 L1 安全命令和量表许可状态。
14. L2 根据结构化状态构造检索请求，而不是只用患者原句检索。
15. 通用 RAG 返回少量互补范式，例如阶段范式 症状范式和 OARS 范式各一条。
16. 模型结合范式生成自然回复，不能复制示例中的患者事实。
17. 现有 MI 回复校验 量表规则 信息充分度和出口守卫继续执行。
18. 检索 knowledge id 写入调试记录，但不能写入患者 evidence nodes。

任务清单

编号	任务	具体工作	交付物	验收标准
L2K1	来源清单	寻找公开 MI 问诊 量表沟通和心理访谈资料并记录许可	来源与许可清单	每条资料可追溯且允许当前用途
L2K2	标签体系	定义 MI 阶段 OARS 技术 症状领域 对话意图和禁忌标签	标签词典和映射表	同一标签含义唯一 覆盖现有 L2 字段
L2K3	知识卡加工	把原始资料整理成推荐范式 反例和适用条件	标准化知识卡文件	无患者隐私 无诊断越界 有人工审核状态
L2K4	术语库	整理症状 情绪 认知模式 患者目标和改变动机表达	术语及同义表达库	只帮助理解 不直接写入患者事实
L2K5	量表范式	整理六个量表的解释 同意 拒绝 中断和自然穿插范式	量表沟通知识卡	不改写题干 不绕过患者许可
L2K6	检索构造	使用阶段 待补字段 症状领域和许可状态生成查询	L2 检索适配器	查询不包含未经确认的推断字段
L2K7	Prompt 接入	将 Top K 范式作为参考加入现有 L2 调用	Prompt 组装调整	检索失败时可按现有流程继续且不伪造知识
L2K8	质量验证	验证 MI 风格 单问题优先 量表时机和禁止诊断	测试集和人工抽检报告	回复自然且不因 RAG 破坏规则控制

验收场景

- 患者首次表达压力时，系统优先建立关系，不立即触发量表。
- 患者提及失眠后，系统能检索睡眠探索范式并提出一个自然问题。
- 建议 PHQ 9 前能说明用途 时长和非诊断性质，并征得同意。
- 患者拒绝量表时继续临床访谈，不重复强迫邀请。
- 知识库示例中的人物 症状和分数不会进入当前患者画像。

负责人交付边界

- 负责人 MI 资料 数据和 L2 开发成员；接入点为 layer2 service dialogue llm client 和 mi response validator。
- 不得修改 L1 安全决策 量表题目和分值规则 L2 到 L3 最低字段要求。

三 L3 临床诊断知识库

L3 知识库为 CLINICR 提供外部诊断标准、排除条件和鉴别诊断依据。它不替代当前候选生成、逐条排除和 Verifier，只为这些步骤补充有版本和来源的临床知识。患者证据与临床知识必须分别保存，不能相互替代。

知识范围

知识类别	必须记录的内容	CLINICR 用途
疾病概览	名称 编码 核心表现 病程 功能损害和主要排除条件	Step 1 同时考虑规定的 10 种障碍
诊断标准	条目代码 名称 标准内容 核心性 数量和组合要求	Step 2 逐条核对
排除条件	物质 药物 躯体疾病 躁狂史 精神病性症状等	阻止不满足核心条件的候选通过
鉴别诊断	共同症状 关键差异和补充问题	比较候选并返回 L2 补充信息
严重度和转介	严重度依据 安全条件和专业转介提示	疗法匹配前的规则输入
来源信息	机构 文件 版本 章节 页码 网址 许可和生效日期	建立知识证据链和更新管理

双证据链要求

每条标准判断必须同时包含 patient evidence refs 和 knowledge refs。前者指向 L2 记录的患者原话或量表答案，后者指向临床知识库中的标准条目。只有患者证据不能证明采用了正确标准，只有知识条目也不能证明患者满足该标准。

证据类型	回答的问题	示例	来源
患者证据	患者实际报告了什么	EV 023 最近一个多月整个人都没劲	L2 对话和证据节点
临床知识	这项表现对应哪条标准	CLINICAL MDD A1 001	官方或合法授权资料
条目结论	为什么标为符合 不符合或待确认	A1 met 并引用两类证据	L3 结构化判断

接入现有 CLINICR 的流程

19. Step 1 使用 10 种障碍的受控概览知识，模型仍需完整考虑规定范围。
20. Step 1 生成 3 至 5 个候选后，按候选疾病代码和资料版本精确检索完整标准包。
21. 每个候选标准包包含诊断条目 病程 功能损害 排除和鉴别信息。
22. Step 2 只允许引用本次标准包中的 knowledge refs 和患者画像白名单中的 evidence refs。
23. 规则验证条目覆盖 数量门槛 核心条件 引用存在性和版本一致性。
24. Verifier 独立检查证据充分性 逻辑连贯性 鉴别覆盖和推理跳跃。
25. 缺少患者证据时返回 L2，临床知识库不可用时报告知识检索错误，不能依赖模型记忆补齐。

任务清单

编号	任务	具体工作	交付物	验收标准
L3K1	来源与授权	确定官方分类 临床指南 专业机构资料和允许使用的范围	来源 版本和许可登记	无来源或无授权资料不进入知识库
L3K2	疾病映射	为当前 10 种障碍建立标准名称 编码 同义词和内部标签	疾病映射表	名称和编码唯一 可用于精确过滤
L3K3	疾病概览	整理核心表现 病程 功能要求和主要排除项	10 种障碍概览卡	Step 1 能完整加载且版本一致
L3K4	标准条目	按疾病和标准代码拆分条目并标记核心性 数量和组合要求	结构化 ClinicalCriterion	条目代码完整且有来源位置
L3K5	鉴别知识	整理候选间共同表现 关键差异和建议补充字段	鉴别诊断知识卡	能映射到 L2 可收集字段
L3K6	标准包构建	按候选疾病生成固定版本的 Clinical Knowledge Pack	标准包服务	一次诊断过程不混用不同版本
L3K7	CLINICR 接入	把概览接入 Step 1 完整标准接入 Step 2	L3 知识适配器	保留候选数量 门槛 回环和 Verifier 独立性
L3K8	双引用守卫	验证 patient evidence refs 和 knowledge refs 均来自白名单	L3 输出校验规则	未知引用 缺失来源和虚构标准均被拒绝
L3K9	临床抽检	按疾病检查标准完整性和结论可解释性	覆盖矩阵和审核记录	10 种障碍均通过资料和流程验收

负责人交付边界

- 建议负责人 L3 开发成员和临床资料审核成员共同负责。
- 主要接入点 layers layer3 diagnosis clinicr llm client api 和 output validator。
- 不得修改 CLINICR 三步顺序 候选置信度门槛 Verifier 独立评分和 L3 到 L2 回环原则。
- 资料要求 DSM 相关材料必须确认版权和授权，优先使用公开可用的 ICD 及权威临床指南。

四 Patient Agent

Patient Agent 用于开发和测试环境，模拟具有固定背景、症状和行为模式的患者，与完整系统进行多轮交互。它帮助团队复现复杂路径和自动运行疗程，但不能代替真实患者评估，也不能进入生产患者流程。

病例模型

字段组	内容	用途
基本背景	年龄段 工作 家庭关系和主要事件	保持病例上下文一致
临床事实	症状 病程 功能影响 量表潜在答案和排除条件	回答 L2 并验证 L3
心理特征	情绪 认知模式 核心信念 目标和改变动机	模拟 MI 和治疗响应
风险脚本	无风险 模糊风险 明确意念 计划和即时危机	覆盖 L1 安全路径
披露策略	主动信息 隐藏信息 需要追问的信息和拒答条件	避免首次回答泄露全部病例
行为参数	合作程度 表达长度 情绪强度 反复和矛盾	生成不同类型患者
变化轨迹	改善 无变化 恶化 复发和退出	测试疗程推进与终止

运行流程

26. 测试控制器加载固定 PatientScenario 和随机种子。
27. Patient Agent 根据病例隐藏状态生成首条患者消息。
28. 完整系统从 L1 开始处理并返回患者可见回复。
29. Patient Agent 只根据病例事实 对话历史和披露策略回答。
30. 测试控制器记录每轮输入 路由 输出 状态和预期事件。

31. 达到终止条件 危机转介 人工复核或最大测试轮数后结束。

32. 评测器检查事实一致性 路径覆盖 证据完整性和终止结果。

任务清单

编号	任务	具体工作	交付物	验收标准
PA1	PatientScenario	定义背景 临床事实 风险 披露策略和变化轨迹	病例 Schema 和示例	病例字段完整且不依赖自由文本猜测
PA2	病例库	建设低风险 高风险 信息不足 共病和诊断排除等病例	版本化测试病例	每个病例有预期路径和关键事实
PA3	患者生成器	根据隐藏状态和历史生成自然患者回复	Patient Agent 模型适配器	不泄露系统提示 不添加病例外事实
PA4	一致性守卫	校验病程 量表 风险和背景前后一致	事实一致性检查器	矛盾输出被记录并终止该次评测
PA5	自动对话控制	循环调用完整系统 API 并处理确认 暂停 量表和治疗	场景运行器	能自动完成评估 诊断 治疗和结案路径
PA6	停止条件	配置最大轮数 目标事件 危机 人工复核和系统终止	测试级终止控制	测试不会无限运行且不冒充疗程终止器
PA7	评测报告	统计路径覆盖 错误类型 事实一致性和模型耗时	结构化报告	失败可定位到层级和具体轮次

验收场景

- 低风险抑郁样例完成 L2 画像确认并进入 L3。
- 信息不足样例触发 L3 返回 L2 并能补充指定字段。
- 明确危机样例在 L1 进入安全路径且不调用后续层。
- 候选诊断被排除时，Patient Agent 保持原病例事实不迎合系统。
- 治疗改善 无改善和主动退出三种轨迹能够触发不同终止结果。

负责人交付边界

- 负责人 智能体和自动化测试成员；建议目录为 simulation patient agent 和 tests scenarios。
- 不得修改 生产环境患者处理逻辑 诊断标准和治疗决策门槛。

五 前端和完整系统 API

前端应通过一个完整系统 API 调用顶层编排器，不分别调用 L1 至 L5。现有 main.py 是终端入口，现有 L4 API 只覆盖治疗层，均不能单独承担完整前端后端接口。前端工作因此包含完整系统 API 封装和两类界面。

角色和界面

界面	主要功能	禁止展示
患者端	自然语言对话 量表交互 画像确认 暂停恢复 安全提示和疗程结束信息	候选诊断 内部评分 原始 Prompt 和开发调试信息
开发者端	当前路由 L1 风险 L2 画像 L3 证据 L4 指令 L5 审核 RAG 命中和 Agent 状态	API 密钥 未脱敏个人信息和无权限会话
演示控制台	选择测试病例 启动 Patient Agent 查看流程和导出结果	生产患者操作入口

完整系统 API

接口	用途	主要返回
创建会话	建立顶层会话并返回初始状态	session id 路由和初始提示
发送消息	把患者消息交给顶层编排器	患者回复 等待类型 路由和错误码
画像确认	提交继续 修改或暂停决定	下一步状态和患者可见回复
提交量表	提交当前许可题目的答案	下一题或返回访谈
暂停恢复	控制患者主动暂停状态	当前可执行动作
获取开发状态	读取开发者可见的流程快照	各层结构化状态和证据
获取疗程总结	读取 L5 生成的周期总结	EpisodeSummary
获取历史疗程	读取外部 Memory	脱敏疗程列表和版本

任务清单

编号	任务	具体工作	交付物	验收标准
FE1	用户流程	绘制患者评估 画像确认 诊断等待治疗 安全和结案流程	页面流程图和状态表	每个编排状态有对应页面和可执行操作
FE2	系统 API	用 Web 服务封装 FiveLayerOrchestrator 和会话操作	完整系统后端接口	前端不直接调用单层且错误码稳定
FE3	患者聊天	实现消息 处理中状态 量表卡 确认卡 暂停和结束	患者端 Demo	患者看不到开发者字段且异常有明确提示
FE4	开发者面板	展示路由 画像 候选诊断 双证据链 指令 审核和 RAG 结果	可视化调试面板	数据来自结构化状态而非解析终端文本
FE5	Agent 控制台	选择病例 启动停止自动对话和查看逐轮记录	测试演示页面	与真实患者入口明确隔离
FE6	错误状态	区分 API 错误 超时 Schema 错误 知识检索错误 人工复核和会话停止	错误映射表和页面	错误不会显示密钥或内部堆栈
FE7	会话与 Memory	刷新后按会话 ID 恢复可持久化状态并查看历史	恢复和历史界面	不能从开发者画像 HTML 恢复会话
FE8	联调与演示	完成手工患者和 Patient Agent 两条演示路径	可运行 Demo 和演示脚本	从创建会话到疗程总结可完整操作

负责人交付边界

- 建议负责人 前端成员负责页面，后端接口成员负责完整系统 API。
- 主要接入点 orchestration orchestrator session store 和新增系统级 API 目录。
- 不得修改 前端不得自行计算风险 诊断 量表分数 疗法或审核结果。

六 联调顺序和里程碑

里程碑	并行工作	完成条件
M1 接口冻结	五项负责人共同确认 Schema 和文件边界	接口文档完成且 Schema 一致性测试通过
M2 数据可用	L2 和 L3 分别完成首版知识数据	来源 许可 标签和人工审核字段完整
M3 检索可用	RAG 完成两库隔离检索	固定查询集能返回预期 Top K 和来源
M4 层级接入	L2 和 L3 分别接入 RAG	原有规则和守卫仍通过 检索失败可定位
M5 自动模拟	Patient Agent 调用完整系统 API	能完成评估 回环 治疗和终止场景
M6 前端联调	患者端 开发者端和 Agent 控制台接入	完整流程不依赖终端文本
M7 项目验收	真实 LLM 受控模型和人工抽检	功能 流程 证据 错误和演示清单全部通过

推荐并行安排

角色	主任务	需要配合的成员
项目和接口负责人	统一 Schema 文件边界 合并和里程碑验收	全部成员
RAG 负责人	R1 至 R8	L2 知识 L3 知识和后端成员
L2 知识负责人	L2K1 至 L2K8	数据审核 RAG 和 L2 成员
L3 知识负责人	L3K1 至 L3K9	临床审核 RAG 和 L3 成员
Patient Agent 负责人	PA1 至 PA7	测试 后端和前端成员
前端负责人	FE1 FE3 至 FE8	系统 API 和各层负责人
系统 API 负责人	FE2 及鉴权 错误和会话接口	编排器 前端和 Memory 成员

角色	主任务	需要配合的成员
测试负责人	固定查询集 场景集 集成测试和验收记录	全部成员

七 全局验收清单

☐ L2 和 L3 使用不同 collection，不发生知识混检。

☐ 所有检索结果包含 knowledge id 来源 版本和相关性分数。

☐ L2 知识示例不会进入患者证据节点，也不会提前生成诊断。

☐ L3 每条关键诊断判断同时引用患者证据和临床知识。

☐ RAG 不可用时能区分检索错误 API 错误和 Schema 错误。

☐ Patient Agent 不会添加病例外事实，测试能够按条件停止。

☐ 患者端只展示患者可见内容，开发者端不泄露 API 密钥。

☐ 前端只调用完整系统 API，不逐层拼装 L1 至 L5。

☐ 原有 L1 至 L5 自动化测试继续通过。

☐ 新增或修改 Pydantic 模型后，Schema 参考文档已经同步生成并通过一致性测试。

☐ 真实 LLM 测试和受控模型测试分别记录，不能用受控模型结果代替真实 API 结论。

☐ 项目演示能够从创建会话运行到疗程终止和总结查看。

八 成员提交规范

每位负责人提交任务时，应同时提交代码或数据、接口说明、测试结果和未解决问题。提交记录至少包含以下内容。

- 任务编号和负责人。
- 本次新增或修改的文件。
- 输入 输出和错误类型。
- 自动化测试命令和结果。
- 真实 LLM 测试是否执行及使用的模型配置。
- 已知限制和需要其他成员配合的接口。
- 下一阶段计划和预计完成时间。